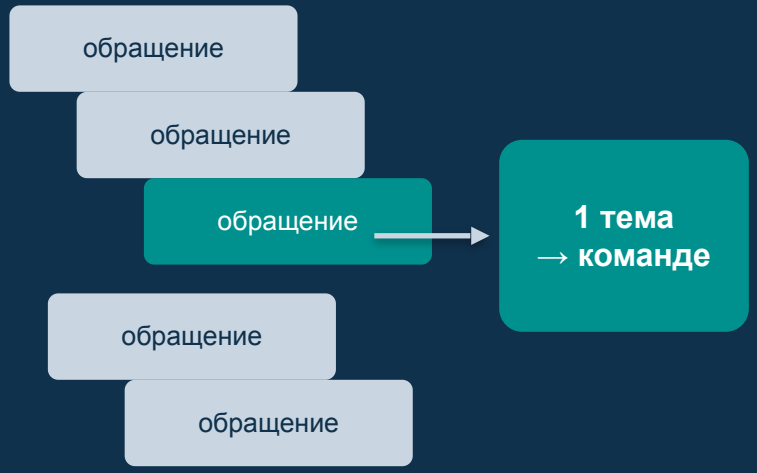
INTELLIGENCE CUP 2026 · КЕЙС «ГАЗПРОМ НЕФТИ»

ИИ-агент, который слышит повторяющиеся просьбы пользователей



Из техподдержки — в продуктовые команды

0

внешних API — только внутренние Qwen

≤ 8

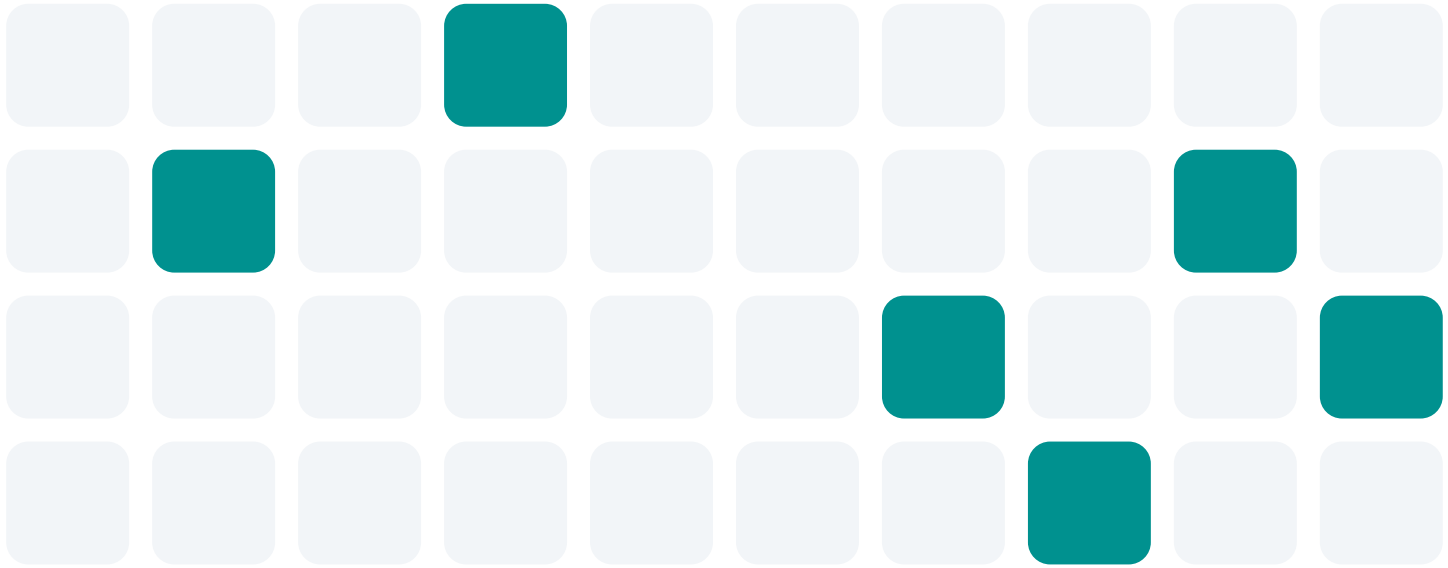
вызовов инструментов на кластер

0,86

найденных тем на holdout (BM25: 0,14)

ПРОБЛЕМА

Каждый видит 1–2 обращения. Сумму не видит никто



40 менеджеров · одна и та же просьба у шести · повтор не видит никто

«Не приходит код-смс для восстановления пароля»

≈ 40

менеджеров поддержки

2 канала

звонки с записью · единое окно

0 ч

дополнительной нагрузки на поддержку

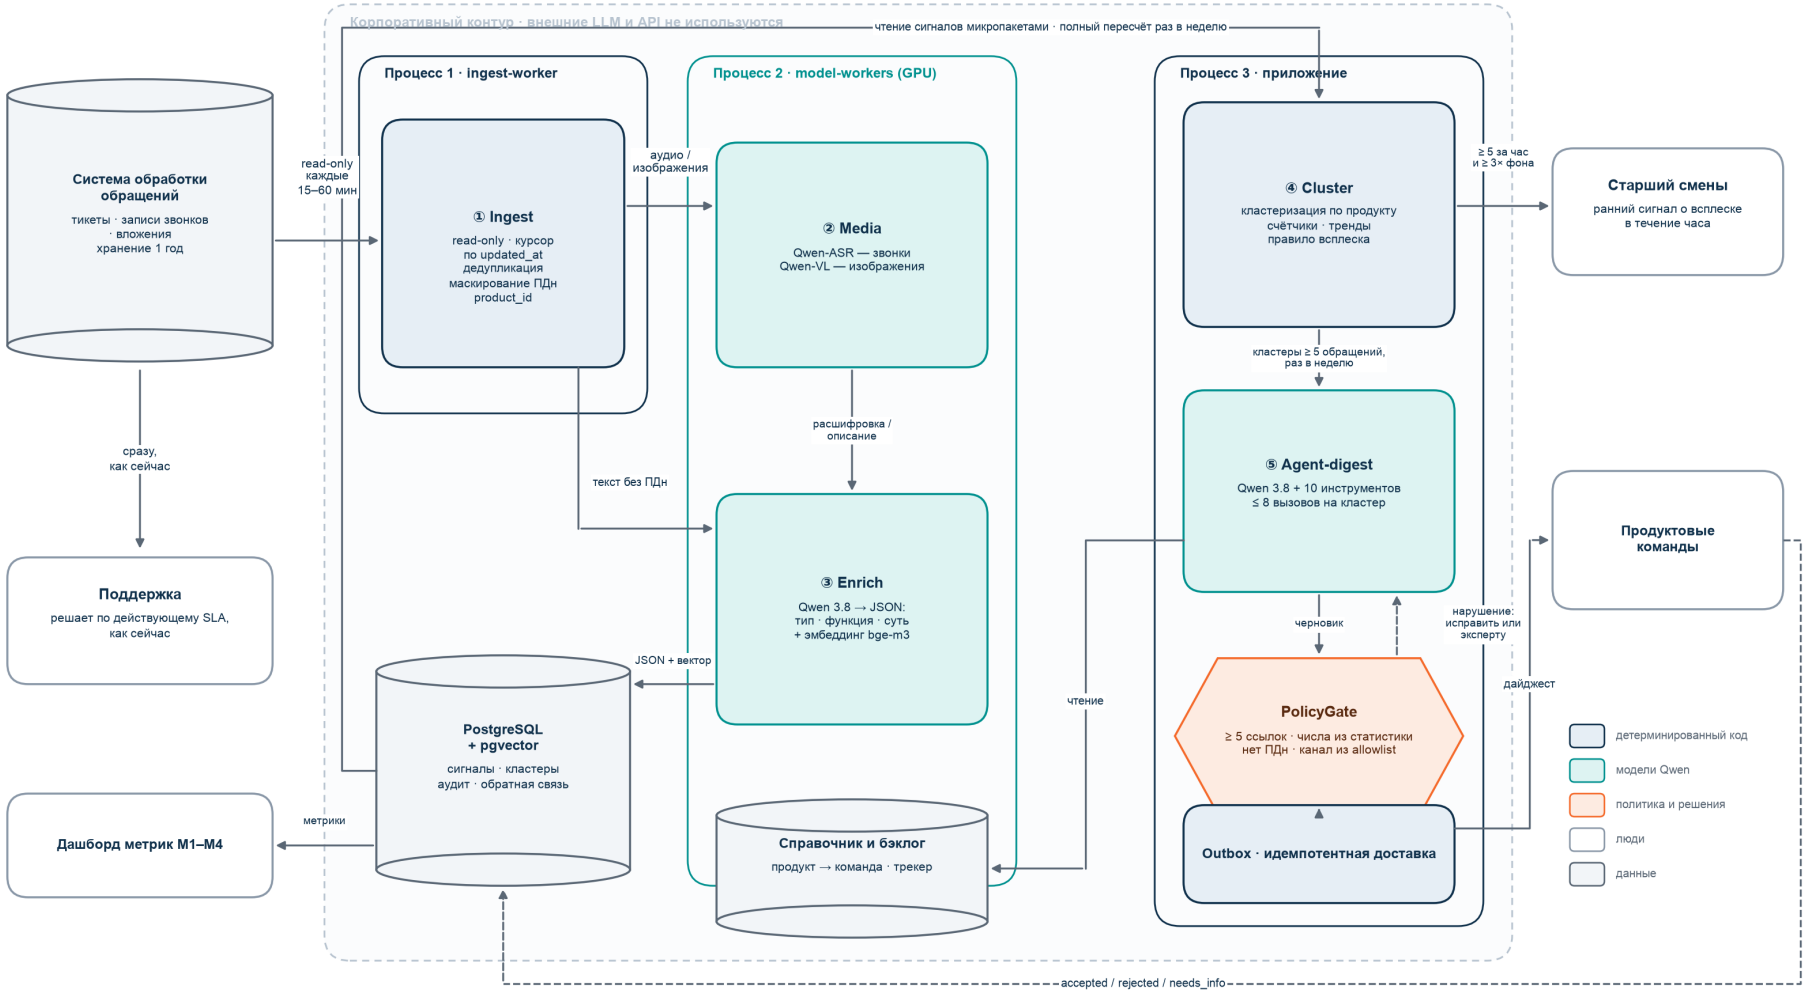
БИЗНЕС-ПРОЦЕСС

Агент работает рядом с поддержкой, а не вместо неё



АРХИТЕКТУРА

5 логических сервисов — 3 процесса — 1 база данных



0

внешних API
Qwen 3.8 · Qwen-ASR · Qwen-VL

3

процесса
ingest · model-workers · приложение

1

база данных
PostgreSQL + pgvector

РАСЧЁТ НАГРУЗКИ

Нагрузка укладывается в ночное окно существующих GPU

≈ 1 400
обращений в день

≈ 0,9 млн
токенов Qwen в день ≈ 15 мин

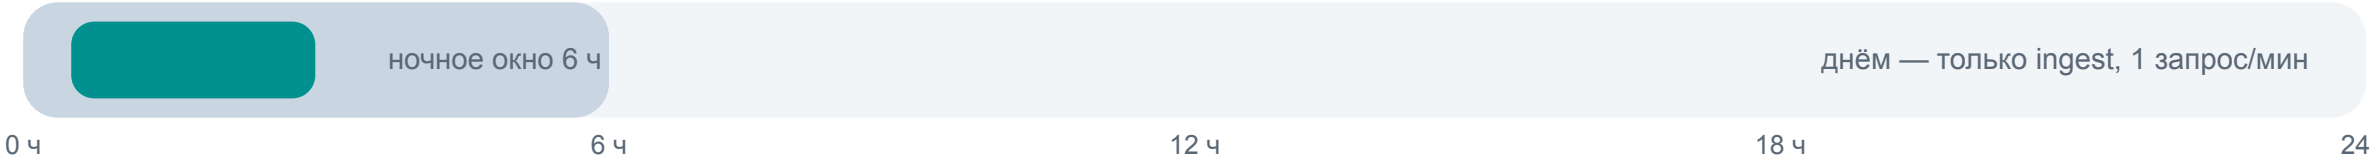
≈ 2,3
GPU-часа ASR в день

≤ 240
вызовов агента в неделю

≈ 1,4 ГБ
эмбеддингов за год

1 / мин
запрос к системе обращений

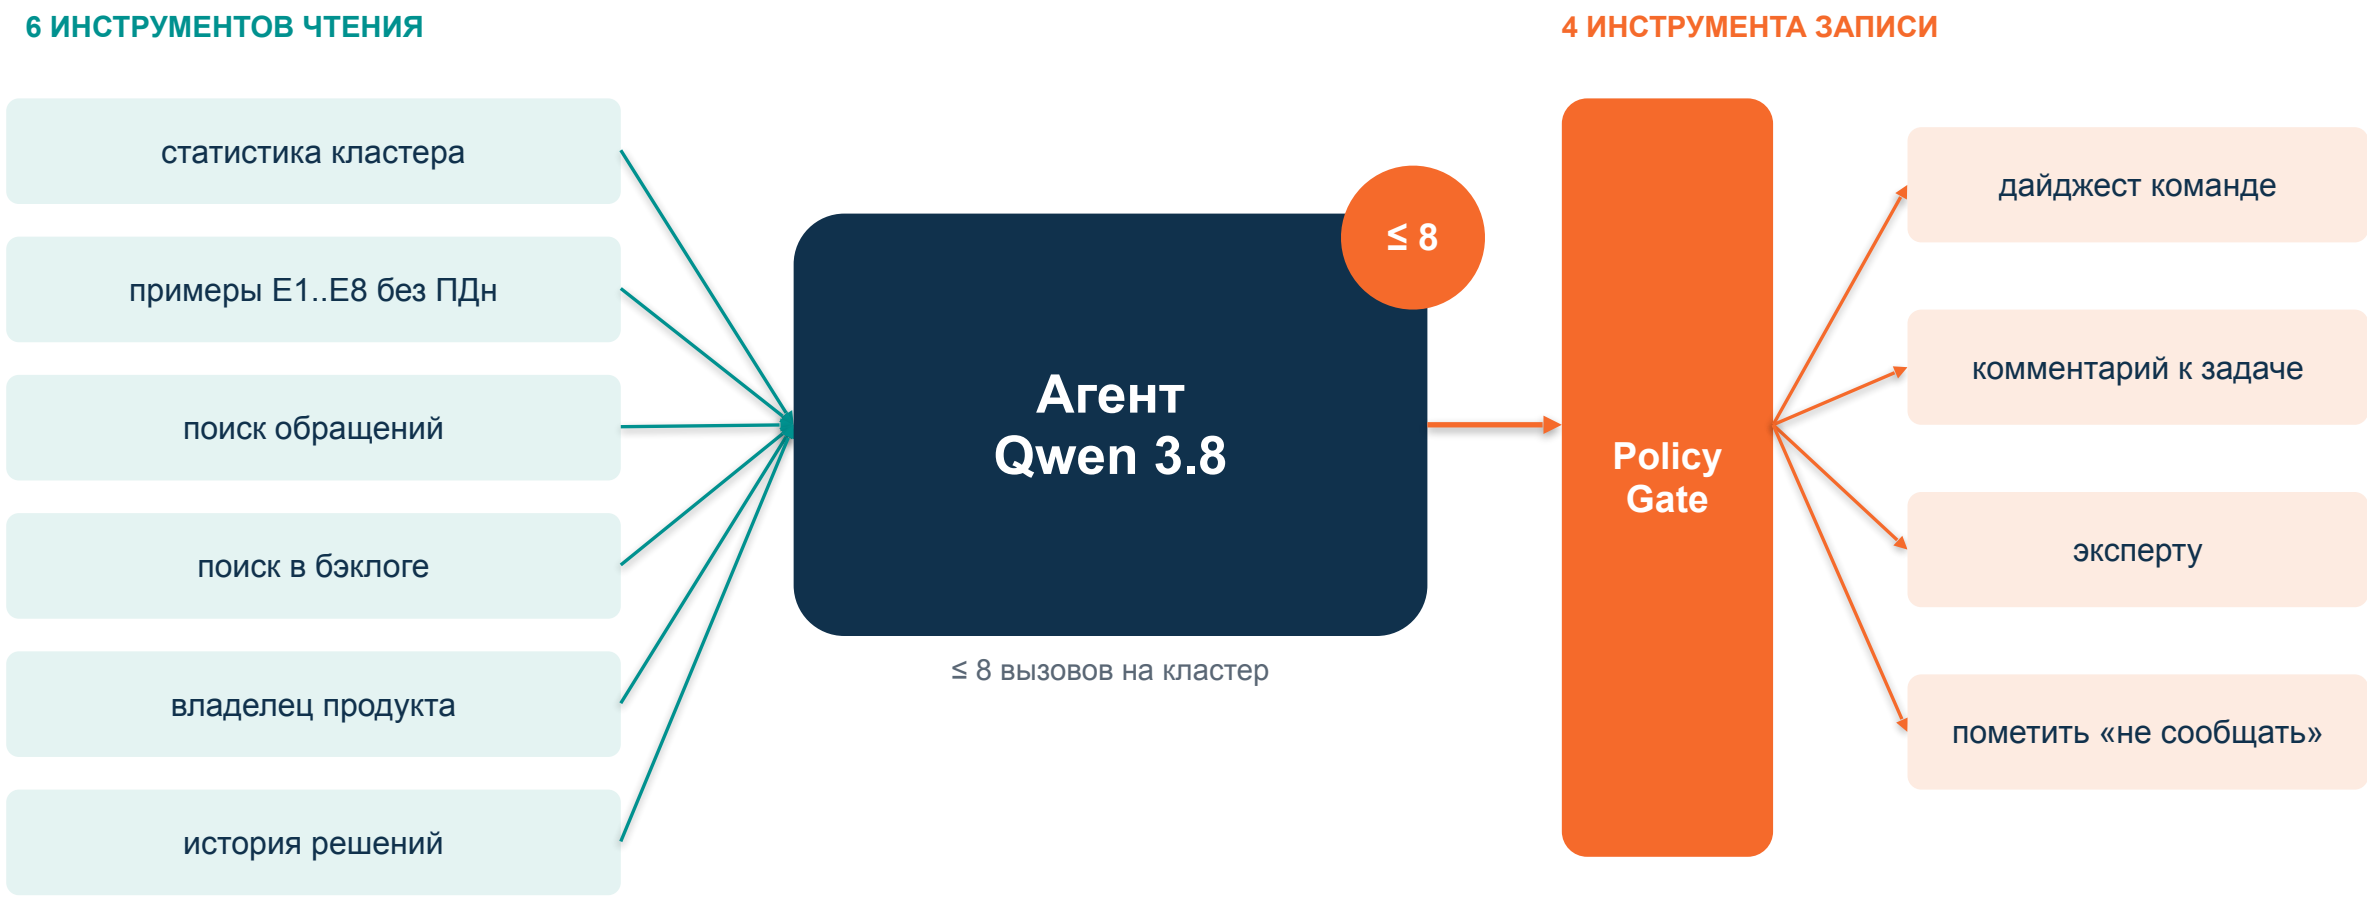
Сутки GPU: ≈ 2,5 ч работы умещаются в ночное окно



ASR — только для звонков без метаданных · кэш классификации по хешу текста

АГЕНТ И ИНСТРУМЕНТЫ

10 инструментов, 4 исхода, не более 8 вызовов



не создаёт задачи

не меняет приоритеты

≥ 5 ссылок из 8 примеров

числа — только из статистики

Промпт задаёт поведение, код гарантирует безопасность

РОЛЬ → ЦЕЛЬ → ВХОД → ИНСТРУМЕНТЫ → **ПРАВИЛА** → ФОРМАТ → ПРИМЕР

7 блоков промпта · 4 явных исхода, включая «не сообщать»

123

Числа

только из статистики
PolicyGate сверяет каждое

E1…E8

Ссылки

примеры вместо ID
≥ 5 из своего кластера

•••

ПДн

маска до модели
проверка на выходе

</>

Prompt injection

текст обращения — данные
канал только из справочника

Пароль или SMS-код агент не предлагает никогда (примеры кейса №6–7)

ТЕСТИРОВАНИЕ

Приёмка: офлайн → shadow → пилот → масштаб

Офлайн	Shadow	Пилот	Масштаб
golden set ≈ 800 F1 ≥ 0,85 · темы ≥ 80%	4 недели ≥ 70% «полезно»	2–3 продукта принято ≥ 50%	все продукты < 40% три недели → пересмотр

HOLDOUT: 204 НОВЫХ ОБРАЩЕНИЯ · QWEN3:8B ЛОКАЛЬНО

0,96
macro-F1 классификации

0,92
recall сервисных запросов

100 %
чисел совпали со статистикой

0
утечек ПДн · дублей

0,86
найдено тем (BM25: 0,14)

Релиз — нижняя граница Уилсона доли принятых ≥ 0,5 на ≈ 250 оценках

ЭФФЕКТ ВНЕДРЕНИЯ

Главное — сколько обращений не случилось

M1 Предотвращённые обращения

M2 Часы ручного сбора

M3 Опережение бэклога

M4 Доля принятых элементов

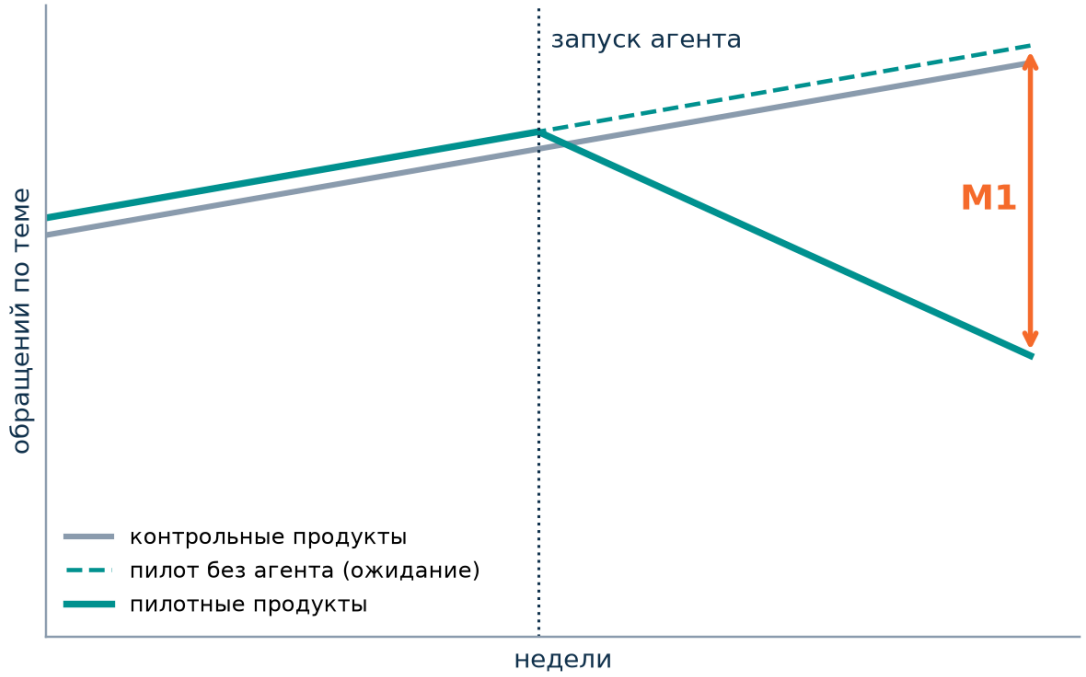


Схема оценки: difference-in-differences

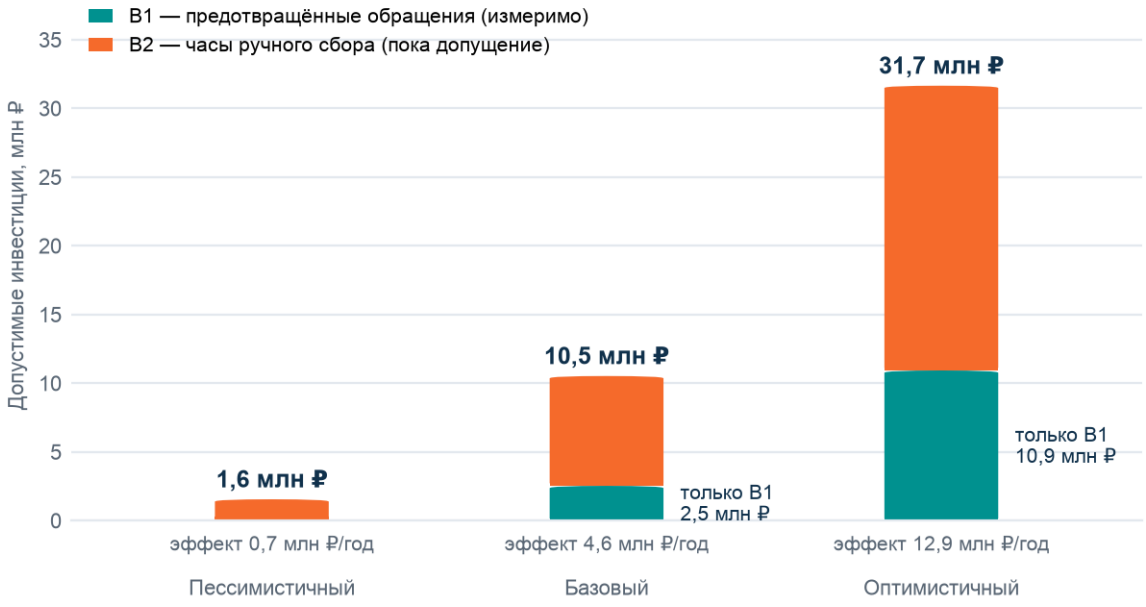
Как считаем M1

1. ретроспектива за год до запуска
2. пилотные продукты против контрольных
3. SLA не хуже · 0 инцидентов ПДн

ФИНАНСОВАЯ МОДЕЛЬ

Эффект ≈ 4,6 млн ₽/год окупает до 10,5 млн ₽ за 3 года

Сколько можно вложить, чтобы окупиться за 3 года



Что сильнее всего влияет на допустимые инвестиции (база 10,5 млн ₽)



B1 — предотвращённые обращения × АНТ × стоимость часа

B2 — часы ручного сбора × 40 менеджеров × 48 нед.

2,5 млн ₽ — потолок только по B1 — минимальный бюджет пилота