ИИ-агент, который слышит повторяющиеся просьбы пользователей

Из техподдержки — в продуктовые команды: проверенные сигналы без дополнительной нагрузки на поддержку

Intelligence Cup 2026 · кейс «Газпром нефти» · Искусственный интеллект

ПРОБЛЕМА

Каждый видит 1–2 обращения. Сумму не видит никто

≈ 40

менеджеров поддержки на всех продуктах в охвате агента (кейс, стр. 4)

2 канала

звонки с записью и единое окно с файлами и картинками; хранение 1 год

0 ч

должно добавиться поддержке — главное требование кейса

Так выглядит повтор в «Вебнефти» (примеры кейса, стр. 6):

«Не приходит код-смс для восстановления пароля»

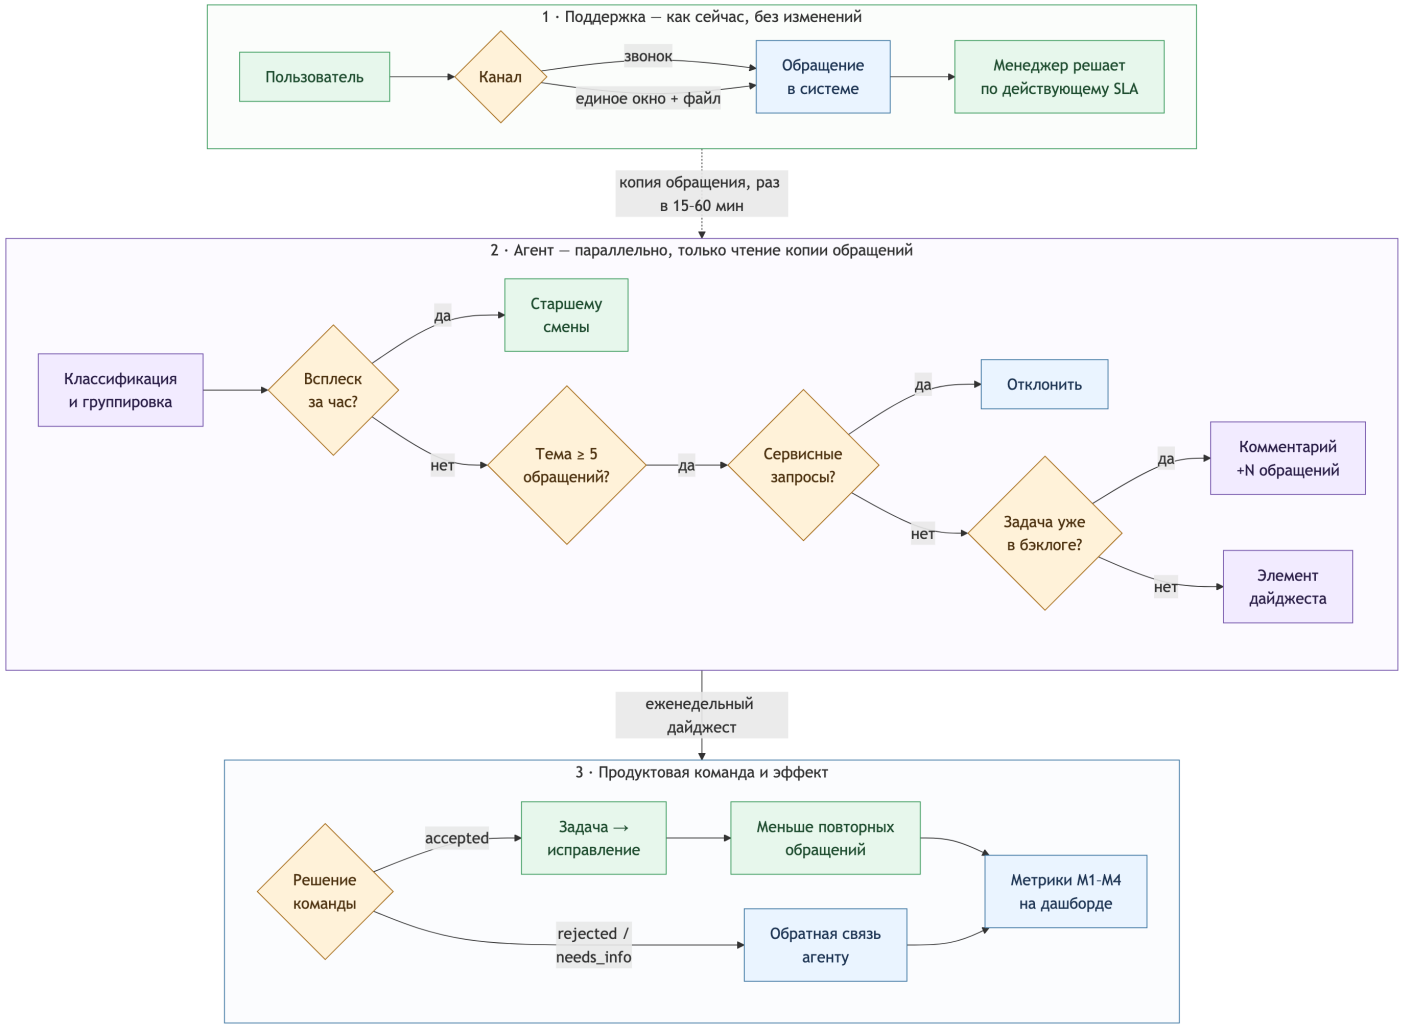
«В личном кабинете нельзя забронировать электронную очередь — ошибка 404»

«Кнопка «Далее» горит синим, но ни в одном браузере не реагирует»

Критичное уже уходит в разработку. Теряются некритичные повторы — пожелания и неудобства, по одному у каждого менеджера.

БИЗНЕС-ПРОЦЕСС

Агент работает рядом с поддержкой, а не вместо неё



SLA не меняется

Срочное (смена телефона перед отгрузкой) решается как сейчас

Два ритма

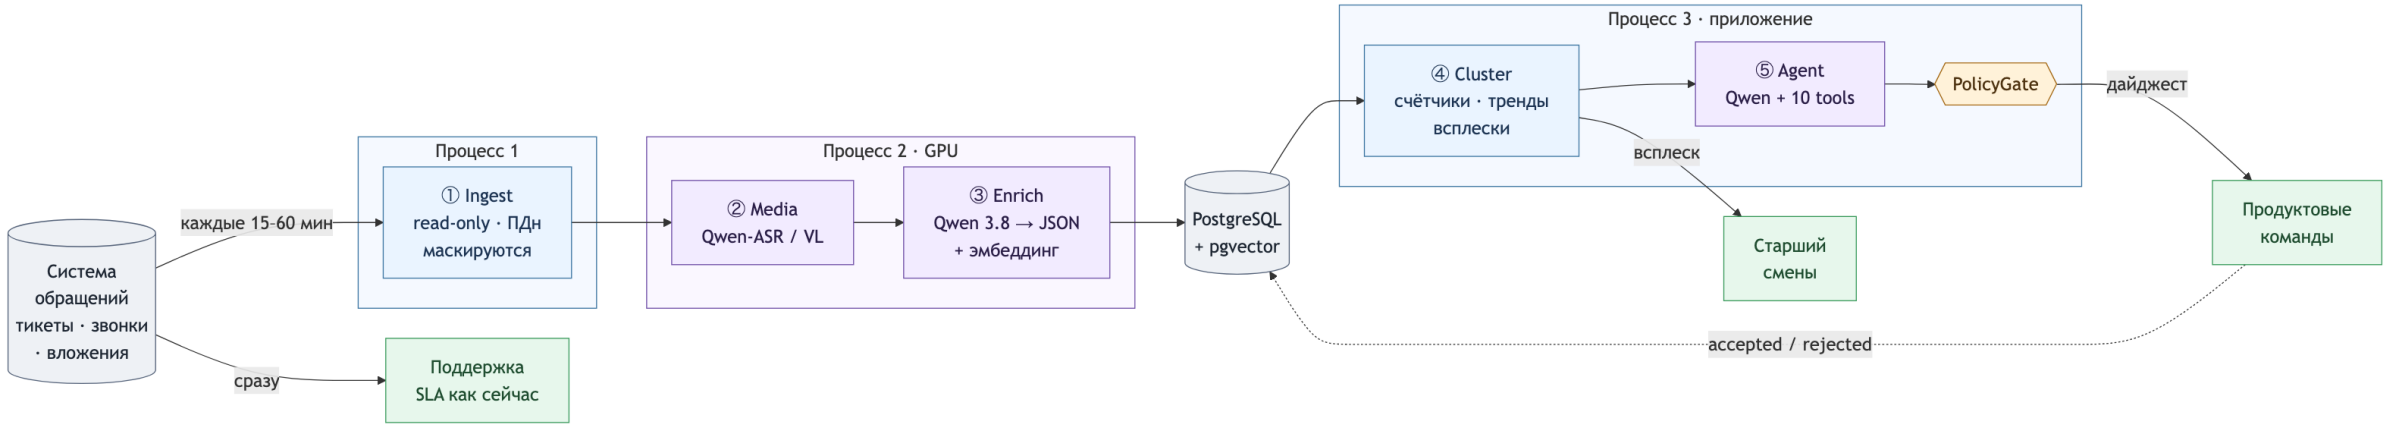
Всплеск за час → старшему смены
Тема ≥ 5 обращений → дайджест раз в неделю

Решает человек

Задачу в бэклоге создаёт команда кнопкой «принять»

АРХИТЕКТУРА

5 логических сервисов — 3 процесса — 1 база данных



Только внутренний контур

Qwen 3.8, Qwen-ASR, Qwen-VL; внешних API нет

Делим по ресурсам и правам

ingest — read-only к источнику · model-workers — GPU · приложение — единственное с правом записи

LLM — только для смысла

классификация и текст дайджеста; числа, группировка, проверки — код

Не добавляем лишнего

без Kafka и отдельной векторной БД: PostgreSQL + pgvector

Свой product_id у обращения

группировка и маршрутизация отдельно по каждому продукту

Отказоустойчивость

Qwen недоступен → повтор в следующем окне; outbox исключает дубли

РАСЧЁТ НАГРУЗКИ

Нагрузка укладывается в ночное окно существующих GPU

≈ 1 400

обращений в день
40 менеджеров × 35

≈ 0,9 млн

токенов Qwen в день
≈ 15 минут работы

≈ 2,3

GPU-часа ASR в день
47 ч звонков, RTF 0,05

≤ 240

вызовов агента в неделю
только кластеры ≥ 5

≈ 1,4 ГБ

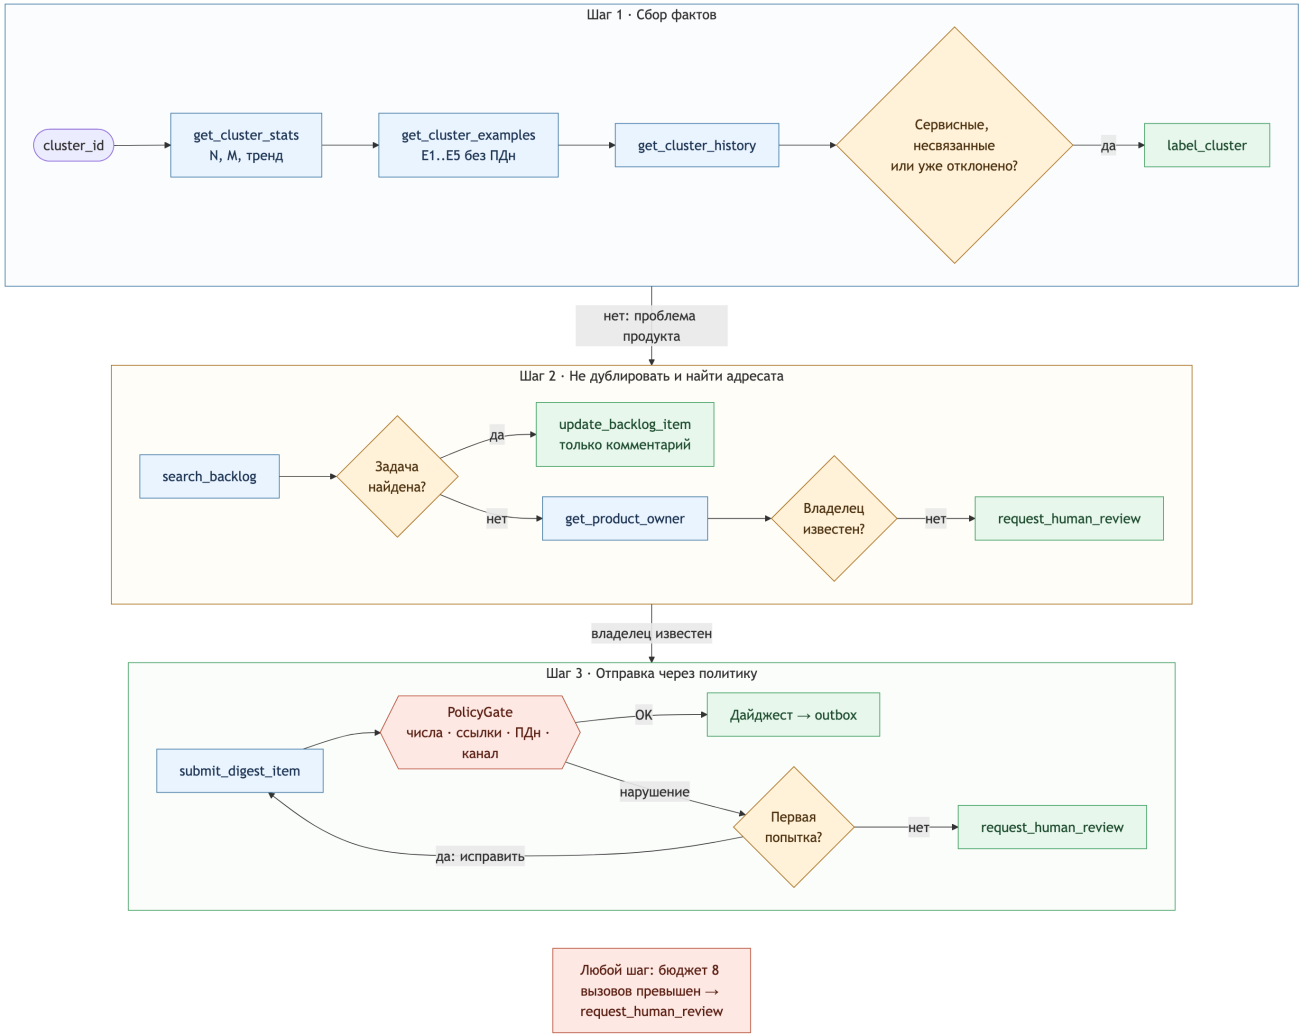
эмбеддингов за год
350 тыс. × 1024

1 / мин

запрос к системе обращений
инкрементальная выгрузка

Как снижаем: ASR только для звонков, которые не классифицируются по метаданным · кэш классификации по хешу текста · агент запускается лишь для тем выше порога. Из кейса известно только число менеджеров — остальное допущения, проверяются на старте.

10 инструментов, 4 исхода, не более 8 вызовов



Чтение — 6

статистика кластера · примеры E1..E5 · поиск обращений · поиск в бэклоге · владелец продукта · история решений

Запись — 4, через PolicyGate

дайджест · комментарий к задаче · эксперту · пометить кластер
Задачи не создаёт и приоритеты не меняет

Промпт задаёт поведение, код гарантирует безопасность

РОЛЬ | ЦЕЛЬ | ВХОД | ИНСТРУМЕНТЫ | **ПРАВИЛА** | ФОРМАТ | ПРИМЕР

7 блоков: узкая роль · 4 явных исхода, включая «не сообщать» · порядок вызовов · формат под продакт-менеджера · пример из кейса

Числа

только из get_cluster_stats — PolicyGate сверяет каждое число

Ссылки

модель видит E1..E5, а не ID тикетов; ≥ 5 ссылок из своего кластера

ПДн

телефоны, e-mail, ИНН, карты маскируются до модели и проверяются на выходе

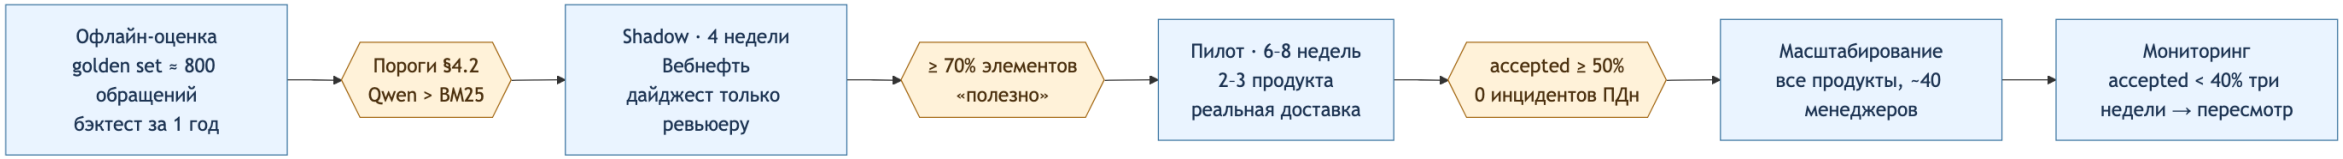
Prompt injection

текст обращения — данные; канал доставки только из справочника

Из примеров кейса: №3 — одно обращение с двумя симптомами считается один раз · №1 и №2 — одна тема ≠ одна ошибка · №6–7 — агент никогда не предлагает выдать пароль или SMS-код

ТЕСТИРОВАНИЕ

Приёмка: офлайн → shadow → пилот → масштаб



Классификация	macro-F1 ≥ 0,85 · сервисные запросы recall ≥ 0,90
Кластеры	чистота ≥ 0,90 · найдено ≥ 80% известных тем
Агент	числа = статистика 100% · дубли с бэклогом ≤ 10% · рубрика ≥ 4/5
Безопасность	0 утечек ПДн · 0 срабатываний prompt injection
Нужен ли Qwen	прототип: найдено тем 0,93 у гибрида против 0,07 у BM25 без LLM
Релиз	нижняя граница Уилсона доли принятых ≥ 0,5 на ≈ 250 оценках

Прототип, 369 обращений, qwen3:8b локально: F1 0,93 · числа 100% · ПДн 0 · дубли 0 · injection заблокирован · всплеск найден

ЭФФЕКТ ВНЕДРЕНИЯ

Главное — сколько обращений не случилось

M1 **Предотвращённые повторные обращения**
темы исправлены раньше × поток обращений

M2 **Высвобожденные часы ручного сбора**
40 менеджеров × часы до и после

M3 **Опережение бэклога**
порог в агенте → задача в бэклоге

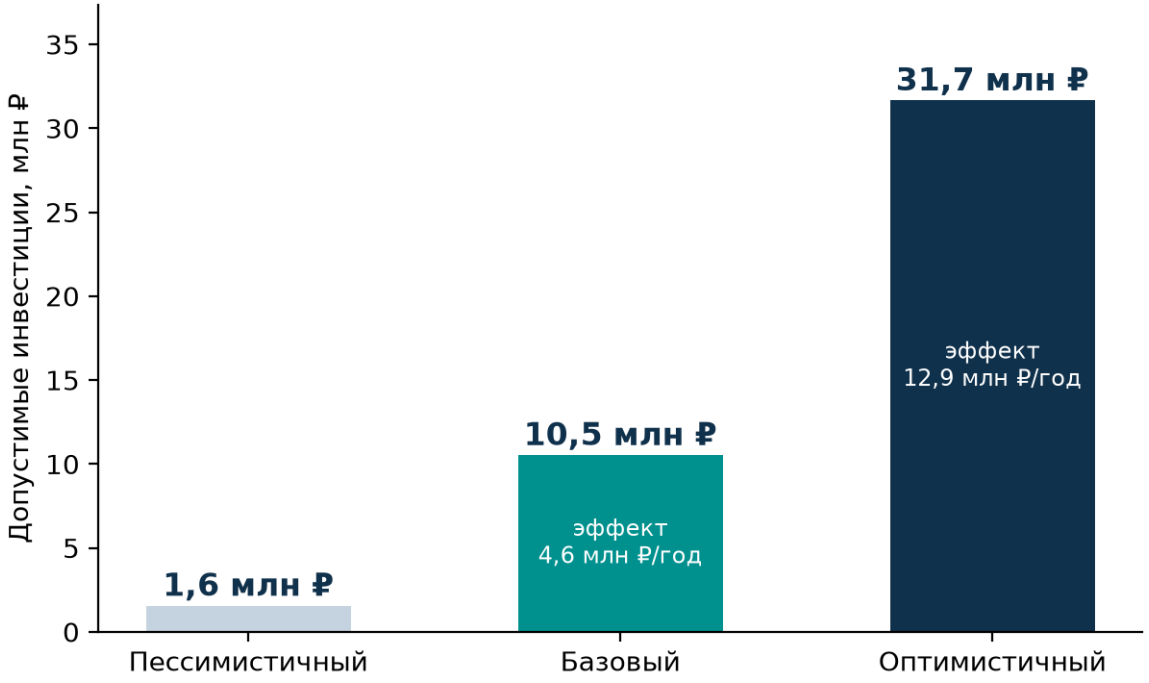
M4 **Доля принятых элементов**
accepted / все решения команды

Ретроспектива за год до запуска · рост по продуктам с контрольной группой (difference-in-differences)

Ограничители: время поддержки на агента ≈ 0 · ложные сигналы · 0 инцидентов ПДн · SLA не хуже.
Нет связи «тикет → задача»? — сопоставление по смыслу + ручная проверка; нет журнала выгрузок? — опрос × 0,7.

ФИНАНСОВАЯ МОДЕЛЬ

Эффект ≈ 4,6 млн ₽/год окупает до 10,5 млн ₽ за 3 года





B1 — предотвращённые обращения × АНТ × стоимость часа · B2 — 40 менеджеров × часы ручного сбора × 48 нед.
r = ключевая ставка (14% на 23.10.2026; прогноз ЦБ 12,5–13,5% в 2027) + 5 п.п. риска; g = 7% (рост зарплат, МЭР).
Бюджет ~10 млн ₽ допускает только компактную архитектуру — поэтому 3 процесса, 1 БД и внутренние модели.